

物体検出に用いられるニューラルネットワークモデル

最新モデルのサーベイと目的に応じたモデルの選択

Neural Network Models for Object Detection

A Survey of the Latest Models and Optimal Model Selections for Specific Tasks

金子 純也

Junya Kaneko

Morning Project Samurai 株式会社

Morning Project Samurai Inc.

junya@mpsamurai.com, <http://www.mpsamurai.com>

山田 貢己

Miki Yamada

(同上)

m.yamada@mpsamurai.com

keywords: survey, neural network, object detection, instance segmentation, deep learning

Summary

「ショートノート」は 200 ワード、それ以外は 200 ~ 500 ワード以内の英文で summary を記す (ここは、論文執筆後に書く。)

ここにチートシートを出力する。

1. ま え が き

この論文の狙い: このサーベイは、理工系大学 2 年生程度の数学の知識を前提に、物体検出をこれから始めるにはどうすればよいかという道すじを伝えることを目的として執筆したものである。物体検出でできることは何? から始まり、物体検出をするために必要なもの (ハード、ソフト、データ、知識、明確な目的) を簡潔に纏めてある。また、読者にとっての理想的なサーベイ (即時性、分かりやすさ、一言で説明、参考文献は充実) というものの一つの解として、随時更新される GitHub 上の (日本語で書かれた) 物体検出まとめサイトとライブラリを紹介する。

世の中の状況: 近年、「AI (人工知能)」という言葉が国内外に蔓延しており、技術者のみならず一般の人の日常生活にもすっかり浸透した。常に手の届くところに AI があり、AI に囲まれて生活していると言っても過言ではない。テレビやインターネットの画像は、本物と見間違えるほどの人工画像で溢れ、スマホや机上のスピーカーに話しかけるとあらゆる情報を教えてくれるばかりでなく、電化製品を操作することもできるようになった。高速道路を自動運転する車も増えている。

AI 分野における物体検出: ここ数年で飛躍的に性能を向上させた AI 関連技術は、画像認識、物体検出、ロボット制御、音声認識、機械翻訳、ビッグデータ分析などであり、これらの多くの領域で深層ニューラルネットワーク (Deep

Neural Network (DNN)) が使われている。この DNN が注目されるようになったのは、2012 年に開催された最先端の一般物体認識の性能を競うコンテスト ILSVRC において DNN を使った手法が他の手法に大差をつけて優勝したことが発端である。「画像中の物は何か?」に答える物体認識をさらに進めて、「画像中のどこに何があるか?」に答えようとするものが本論文のテーマ「物体検出」であり、現在の AI ブームを巻き起こした源流がここにあると言ってよい。

物体検出でできること: 物体検出とは、カメラで撮影された画像データを電子的に処理し、予め登録しておいた物体 (例えば、人、犬、猫、自動車、飛行機、...) を見つけ出し、その正確な画像上の位置と物体の種類を予測するものである。「予測 (predict)」は、「推定 (estimate)」, 「推論 (inference)」などとも呼ばれ全て同じ意味で使われる。

現在の標準的方法においては、予め、検出したい対象の学習データ (物体が写っている画像、物体の種類、物体の位置を示す矩形の座標) を大量に用意し、画像を入力すれば種類と位置を出力するように、ニューラルネットワーク等の予測モデルを学習させる。通常、これに数時間から数日要すると言われている。

学習が完了した予測モデルの能力は、タスクの種類によっては人間の能力 (予測結果のスコアの平均値) を超えたと言われているものもある (物体認識など)。ただし、物体が写し出された画像の品質 (解像度、ノイズ、露出不

足/過多) や撮影アングル (遮蔽物, 変形, 大き (小) 過ぎる) に問題がある場合は性能が低下することは避けられない。

物体検出と似た技術として, 次の 3 つがある:

- セマンティックセグメンテーション (全画素の物体の種類を認識するが, 同種の物体同士は区別しない)
- インスタンスセグメンテーション (同種の異なる個体を区別して物体検出を行い, 且つ, 画素単位で個体の識別をする)
- パノプティックセグメンテーション (全画素の物体の種類を認識し, 同種の異なる個体も区別する)

本論文では上記のセグメンテーション技術も含めた広い意味での物体検出について述べる。

物体検出をするために必要なもの:

ソフトウェア

- PyTorch/TensorFlow 等の深層学習ライブラリとその稼働環境 (Linux/Windows/Mac 上の Python, jupyter notebook 環境など)。
- 物体検出を行うソフトウェア (予測モデルの作者, または, 物体検出を行おうとする担当者が作ったもの)。

ハードウェア

- 前記ソフトウェアが実行できる環境 (PC (GPU があると良い), 或いは, Google Corabulatory などのサーバ上の実行環境)。

データ

- 学習データ (事前学習用, 並びに, fine-tuning 用の入力と出力のペア)
- 本来処理したいデータ (入力)。

これらは, 使用するソフトウェアで読み取ることのできる状態にしておく (データの预处理)。

知識 物体検出のソフトウェアを使うには, 入出力データの意味を理解する必要がある。特に, 予測モデルの出力データは通常は誤差を含むものとなるため, 出力が表す数値が確率値を表すのか, 何らかの物理量を表すのか, 分類のカテゴリを表すのか, 正確に把握する必要がある。また, 学習時の損失関数の値から, 予測モデルの推定誤差を見積もることができるのだが, それには出力結果を正しく解釈できる統計学の知識が必要となる。

明確な目的 何がしたいのかということを明確化しておくことが, 物体検出を行おうとするときに重要となる。物体検出は新しい技術であり, 標準的な統計解析の手法よりも手間と計算コストが大きくなりがちである。他の方法では解決できないのか? と問いかけて, 本当にこれが必要であることを確認しておくべきである。

理想的なサーベイとは: 最新技術のサーベイ論文は, 有用であり様々な分野で昔から (論文雑誌が生まれた頃から) 活用されていると思われる。しかしながら, 進歩の速

い分野においてはサーベイが出た頃には既に内容が古くなってしまっているという問題が往々にして起こる。また, とても良く書かれたサーベイほど内容が濃く多くなり, 執筆に時間と労力を要するのはもちろん, それを読み解くのにも時間を要するということがよくある。

我々は, github 上に随時更新される形式でサーベイを公開することを試みた。出版されたときには既に古くなっているという懸念を取り払える可能性を期待している。また, この分野に新規参入しようとしている人になるべく短時間で必要な情報にたどり着き, 取り組んでいる問題を解決する最適な方法を見つけたり, 或いは, 新たな研究に取り組めることを目指し, 内容の拡充性や緻密性よりも, なるべく視覚的に解りやすいコンパクトな内容になるよう心掛けた。

2. 物体検出 (Object detection)

2.1 Two-stage 検出器

§ 1 Faster R-CNN

§ 2 TFA Net

§ 3 Few-Shot Object Detection

2.2 One-stage 検出器

§ 1 YOLOv4

§ 2 EfficientDet

3. インスタンスセグメンテーション (Instance segmentation)

3.1 Mask Scoring R-CNN (MS R-CNN)

マスク品質 (インスタンスマスクと正解マスクとの IoU として定量化されるもの) を分類スコアと明示的に関連付けたモデルである [Huang 19]。MS R-CNN は, 予測マスクの品質を学習するためのブロック (MaskIoU Head) を, Mask R-CNN [He 17] に導入したモデルになっている (図 1)。MaskIoU Head はインスタンスの特徴量と対応する予測マスクを一緒に取り込み, それを元に Mask

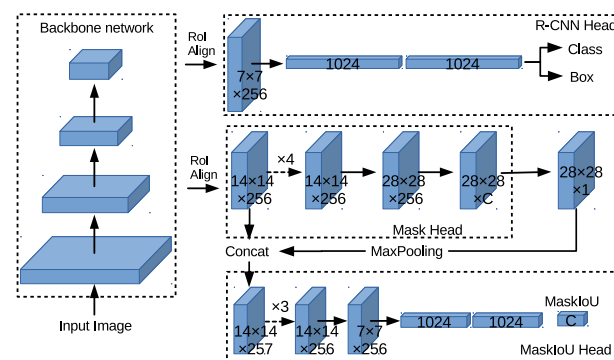


図 1 Mask Scoring R-CNN の構造。

IoU を回帰推定する．そして，推論時に予測 MaskIoU を分類スコアに掛け算して補正する．

§ 1 MS R-CNN の学習

学習サンプルとして RPN proposals を使う．proposal box と正解 box との IoU が 0.5 以上の学習サンプルが必要となる．これは Mask R-CNN の Mask head の学習サンプルの場合と同じである．各学習サンプルに対する回帰目標を生成するために，まず目標クラスの予測マスクを取得し，予測マスクを閾値=0.5 で 2 値化する．そして，2 値化マスクと正解との MaskIoU を使う．MaskIoU を回帰するには L2 損失を使い，損失重みは 1 にする．ネットワーク全体は end-to-end で学習する．

§ 2 MS R-CNN の推論処理

MaskIoU Head は分類スコア (R-CNN head の出力) の調整に使う．推論の手順は次のようになる：

- (1) R-CNN head が N 個の bounding box を出力する．
- (2) N 個の bounding box のうち，SoftNMS[Bodla 17] で上位 k 個のボックスを選択する．
- (3) 上位 k 個のボックスを Mask Head に入力し， k 個のマルチクラスマスクを生成する (ここまでは標準的 Mask R-CNN の手順)．
- (4) これら k 個のマスクを目標として MaskIoU Head に入力し，予測 MaskIoU を出力する．
- (5) 予測 MaskIoU を，分類スコアに掛け算し，上位 k 個の修正された分類スコアを得る．

3.2 YOLACT++

4. パノプティックセグメンテーション (Panoptic(?) segmentation)

5. む す び

謝 辞

謝辞について

◇ 参 考 文 献 ◇

- [Bodla 17] Bodla, N., Singh, B., Chellappa, R., and Davis, L. S.: Soft-NMS Improving Object Detection with One Line of Code, in *2017 IEEE International Conference on Computer Vision (ICCV)*, pp. 5562–5570 (2017)
- [He 17] He, K., Gkioxari, G., Dollr, P., and Girshick, R.: Mask R-CNN, in *2017 IEEE International Conference on Computer Vision (ICCV), Venice*, pp. 2980–2988 (2017)
- [Huang 19] Huang, Z., Huang, L., Gong, Y., Huang, C., and Wang, X.: Mask Scoring R-CNN, in *Proc. of IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 6409–6418 (2019)

〔担当委員：××〕

19YY 年 MM 月 DD 日 受理

◇ 付 録 ◇

A. 付録のタイトル 1

付録の本文 1

—— 著 者 紹 介 ——

金子 純也(正会員)
著者 1 の略歴

山田 貢己(正会員)
1989 年東京大学大学院物理学専攻修了．理学博士．同年株式会社東芝入社．ニューラルネットワークの研究開発，セキュリティ技術，画像認識技術，テレビの高画質化技術，車載画像認識プロセッサ等の開発業務に従事．2020 年ジャパニアス株式会社に入社．現在，Morning Project Samurai 株式会社において AI 開発業務に従事．